

Obligatorisk Opgave 2

Sandsynlighedsregning og Statistik

Bastian Thomsen
prk315

19. december 2025

Indledning

I denne opgave kigger jeg på løndata fra 934 tilfældigt udvalgte fuldtidsansatte i staten Connecticut, USA fra 2017. Målet er at finde ud af om lønningerne bedst kan beskrives med en normalfordeling eller en log-normalfordeling.

1 Deskriptiv statistik

Jeg startede med at indlæse datasættet i R og lavede en ny variabel **LogPay** med den naturlige logaritme til lønværdierne. Herefter beregnede jeg de basale statistikker:

	Median	Gennemsnit	Stikprøvevarians	Stikprøvespredning
Pay	81459.68	85577.22	1076703934.22	32813.17
LogPay	11.3079	11.2931	0.1252	0.3539


Tabel 1: Deskriptive statistikker for Pay og LogPay.

R-kode:

```
1 paydata2017 <- read.table("paydata2017.txt", header = TRUE)
2 paydata2017$LogPay <- log(paydata2017$Pay)
3
4 # beregner statistikker
5 median(paydata2017$Pay)
6 mean(paydata2017$Pay)
7 var(paydata2017$Pay)
8 sd(paydata2017$Pay)
```

2 Histogrammer med normalfordelingsoverlay

Jeg tegnede histogrammer for både Pay og LogPay og lagde normalfordelingskurver ovenpå (med gennemsnit og varians fra stikprøven).



Figur 1: Histogrammer for Pay (venstre) og LogPay (højre) med normalfordeling.

2.1 Diskussion

Når man kigger på de to histogrammer kan man ret tydeligt se:

For **Pay**: Histogrammet er meget skævt mod højre. Normalfordelingskurven passer slet ikke - der er alt for mange høje lønninger i forhold til hvad normalfordelingen forudsiger. Den røde kurve rammer bare ikke særlig godt.

For **LogPay**: Her ser det meget bedre ud! Histogrammet er næsten symmetrisk og normalfordelingskurven følger dataene ret pænt. Det tyder på at logaritmen til lønnen faktisk er nogenlunde normalfordelt.

Man kan også se det i tabellen fra før: For Pay er medianen (81460) en del lavere end gennemsnittet (85577), hvilket er typisk når fordelingen er skæv. For LogPay er de næsten ens (11.31 vs 11.29), som man forventer for en symmetrisk fordeling.

Så konklusionen må være at det giver bedre mening at antage at *logaritmen* til lønnen er normalfordelt - altså at lønnen følger en log-normalfordeling.

3 Sandsynlighedsestimater

Nu vil jeg prøve at estimere sandsynligheden for at en tilfældig statsansat tjente over 100.000 USD.

3.1 Med log-normalfordeling

Hvis vi antager $\log(\text{Pay}) \sim \mathcal{N}(\mu, \sigma^2)$, så kan vi regne:

$$\begin{aligned} P(\text{Pay} > 100000) &= P(\log(\text{Pay}) > \log(100000)) \\ &= 1 - \Phi\left(\frac{\log(100000) - \mu}{\sigma}\right) \end{aligned} \quad (1)$$

I R:

```
1 mu_hat <- mean(paydata2017$LogPay)
2 sigma_hat <- sd(paydata2017$LogPay)
3 prob_lognormal <- 1 - pnorm(log(100000), mean = mu_hat, sd = sigma_hat)
4 # giver 0.2673
```

3.2 Empirisk estimat

Man kan også bare tælle hvor mange der rent faktisk tjener over 100.000:

```
1 prob_empirical <- mean(paydata2017$Pay > 100000)
2 # giver 0.2452
```

3.3 Sammenligning

Så vi får:

- Log-normal estimat: ca. 26.7%
- Empirisk: ca. 24.5%

De ligger rimelig tæt på hinanden (kun 2 procentpoint forskel), hvilket er et godt tegn på at log-normalfordelingen passer nogenlunde til dataene. Forskellen skyldes nok bare at vi har en endelig stikprøve og at log-normal kun er en tilnærmelse.

4 Afledning af log-normalfordelingens tæthed

Lad $X \sim \mathcal{N}(\mu, \sigma^2)$ og $Y = e^X$. Jeg skal vise at tætheden for Y er:

$$f_Y(y) = \frac{1}{y\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(\log y - \mu)^2}{2\sigma^2}\right), \quad y > 0$$

Jeg bruger cdf-metoden. For $y > 0$:

$$\begin{aligned} F_Y(y) &= P(Y \leq y) = P(e^X \leq y) \\ &= P(X \leq \log y) \\ &= \Phi\left(\frac{\log y - \mu}{\sigma}\right) \end{aligned} \tag{2}$$

For at finde tætheden differentierer jeg mht. y (kædereglen):

$$\begin{aligned} f_Y(y) &= \frac{d}{dy} \Phi\left(\frac{\log y - \mu}{\sigma}\right) \\ &= \phi\left(\frac{\log y - \mu}{\sigma}\right) \cdot \frac{1}{\sigma} \cdot \frac{1}{y} \end{aligned} \tag{3}$$

hvor $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ er tætheden for standardnormalfordelingen.

Hvis man sætter ind og regner lidt på det:

$$f_Y(y) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(\log y - \mu)^2}{2\sigma^2}\right) \cdot \frac{1}{y} = \frac{1}{y\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(\log y - \mu)^2}{2\sigma^2}\right)$$

Så det passer!

5 Log-normalfordeling for løndata

Hvorfor giver det mening at bruge log-normalfordelingen til at beskrive Pay?

1. Lønninger afhænger af mange ting der “ganges sammen” (uddannelse, erfaring, anciennitet osv.), og når man tager log af et produkt får man en sum - og summer af mange ting er ofte normalfordelte (central grænseværdisætning).

2. Histogrammet fra spørgsmål 2 viste at LogPay så ret normalfordelt ud.
3. Log-normalfordelingen giver kun positive værdier, hvilket giver mening for løn (man kan ikke have negativ løn).
4. Den er naturligt højreskæv, ligesom vores løndata.


5.1 Valg af parametre

Til μ og σ^2 bruger jeg gennemsnittet og variansen af LogPay:

- $\mu = 11.2931$ (gennemsnit af LogPay)
- $\sigma^2 = 0.1252$ (varians af LogPay)

Det giver mening fordi hvis $\log(\text{Pay})$ er normalfordelt, så er disse netop estimaterne for parametrene.

5.2 Grafisk tjek



Figur 2: Histogram af Pay med log-normalfordeling ovenpå.

Kurven ser ud til at ramme dataene ret godt - både toppen og halen passer nogenlunde.

6 Median for log-normalfordelingen

6.1 Median for X

For $X \sim \mathcal{N}(\mu, \sigma^2)$ er medianen bare μ , fordi normalfordelingen er symmetrisk. Man kan også se det ved at $P(X \leq \mu) = \Phi(0) = 0.5$.

6.2 Median for Y

Lad c være medianen for $Y = e^X$. Så skal $P(Y \leq c) = 0.5$.

$$P(Y \leq c) = P(e^X \leq c) = P(X \leq \log c) = 0.5 \quad (4)$$

Men vi ved at medianen for X er μ , så $\log c = \mu$, dvs.:

$$c = e^\mu$$

6.3 Tjek med data

Lad os se om det passer:

- Teoretisk median: $e^{11.2931} = 80267.88$ USD
- Empirisk median fra data: 81459.68 USD

Forskellen er kun ca. 1200 USD, så det passer fint!

7 Forventning af log-normalfordelingen

Jeg skal finde ud af hvilken af disse formler der er korrekt for $\mathbb{E}(Y)$:

$$e^\mu, \quad e^{\mu-\sigma^2}, \quad e^{\mu+\sigma^2}, \quad e^{\mu+\sigma^2/2}, \quad e^{\mu+\sigma}$$

7.1 Simulation

Jeg simulerede med $\mu = 0$ og $\sigma = 1.5$:

```
1 set.seed(123)
2 X_sim <- rnorm(100000, mean = 0, sd = 1.5)
3 Y_sim <- exp(X_sim)
4 mean(Y_sim) # giver ca. 3.07
```

Så sammenlignede jeg med de forskellige formler:

- $e^\mu = e^0 = 1$ (passer ikke, for langt fra 3.07)
- $e^{\mu-\sigma^2} = e^{-2.25} \approx 0.11$ (passer slet ikke)
- $e^{\mu+\sigma^2} = e^{2.25} \approx 9.49$ (for stort)
- $e^{\mu+\sigma^2/2} = e^{1.125} \approx 3.08$ (det passer!)
- $e^{\mu+\sigma} = e^{1.5} \approx 4.48$ (passer ikke)

Så den rigtige formel er:

$$\mathbb{E}(Y) = e^{\mu+\sigma^2/2}$$

8 Estimering af gennemsnitlig løn

Nu bruger jeg formelen til at estimere den gennemsnitlige løn:

```
1 mu_hat <- mean(paydata2017$LogPay) # 11.2931
2 sigma2_hat <- var(paydata2017$LogPay) # 0.1252
3 expected_salary <- exp(mu_hat + sigma2_hat/2)
4 # giver 85455.08
```


Sammenligning:

- Fra log-normal formelen: \$85,455
- Empirisk gennemsnit fra tabellen: \$85,577

Forskellen er kun 122 dollars - det er virkelig tæt på! Det bekræfter igen at log-normalfordelingen er en god model for løndata.

9 QQ-plots

Til sidst laver jeg QQ-plots for at tjekke normalfordelingsantagelsen.



Figur 3: QQ-plots for Pay (venstre) og LogPay (højre).

9.1 Hvad man kigger efter

I et QQ-plot sammenligner man kvantilerne fra data med teoretiske kvantiler fra normalfordelingen. Hvis punkterne ligger på en ret linje, er data normalfordelte.

9.2 Analyse

Pay: Punkterne afviger helt vildt fra linjen, især i højre side hvor de buer opad. Det viser tydeligt at Pay ikke er normalfordelt - der er for mange høje værdier.

LogPay: Her ligger punkterne meget tættere på linjen. Der er måske lidt afvigelser i enderne, men overordnet ser det fint ud. LogPay er altså nogenlunde normalfordelt.

Dette passer med alt det andet vi har fundet i opgaven.

Opsummering

Så hvad har jeg fundet ud af?

1. Løndata er skæve og ikke normalfordelte
2. Når man tager logaritmen bliver det meget tættere på normalfordelt

3. Log-normalfordelingen beskriver løndata godt
4. Både medianen (e^μ) og forventningen ($e^{\mu+\sigma^2/2}$) fra log-normalfordelingen passer godt med de empiriske værdier
5. QQ-plots bekræfter at LogPay er ca. normalfordelt

Alt i alt er log-normalfordelingen en god model for denne type løndata.