

Anden obligatoriske opgave

Bemærkninger

- I en del spørgsmål bliver I bedt om at *forklare*, *diskutere*, eller *kommentere*. Forsøg at lave teksten til disse spørgsmål så præcis som mulig, dvs. overvej grundigt hvad der er relevant (og hvorfor) og hvordan det kan formuleres præcist.
- Nedenfor refererer BH til lærebogen af Blitzstein og Hwang, SM til noterne af Sørensen og Markussen, og RR til notatet om R.
- Der er hjælp at hente til de fleste spørgsmål til sidst i dokumentet — men prøv først at lave spørgsmålene uden hjælp.

Stikprøvevarians og stikprøvespredning

I får brug for størrelserne gennemsnit, stikprøvevarians og stikprøvespredning som derfor defineres her: Lad $x_1, \dots, x_n$ være de observerede værdier af uafhængige identisk fordelte stokastiske variable $X_1, \dots, X_n$. Gennemsnittet er

$$\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i,$$

og vi kan også beregne stikprøvevariansen, s_n^2 , og stikprøvespredningen, s_n :

$$s_n^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad s_n = \sqrt{s_n^2}.$$

Bemærk at der divideres med $n-1$ i stedet for n . Husk desuden at medianen af $x_1, \dots, x_n$ er den midterste værdi når observationerne er ordnet efter størrelse.

Stikprøvevarians og stikprøvespredning kaldes også empirisk varians og empirisk spredning. De engelske betegnelser er “sample variance” og “sample standard deviation”.

Under passende antagelser vil $\bar{x}_n$ nærme sig middelværdien $E(X_i)$ og s_n^2 vil nærme sig variansen $\text{Var}(X_i)$ når $n \rightarrow \infty$. I BH afsnit 6.3 er der nogle formelle middelværdiberegninger der understøtter dette, og der bliver gjort rede for hvorfor man dividerer med $n-1$ i stedet for n , men disse argumenter er ikke en del af denne opgave.

Median, gennemsnit, stikprøvevarians og stikprøvespredning beregnes i R med funktionerne `median()`, `mean()`, `var()` og `sd()`, se afsnit 4 i RR.

Data

Data til opgaven består af årslønnen i 2017 for 934 personer udvalgt tilfældigt blandt samtlige fultidsansatte statsansatte i delstaten Connecticut i USA.

Data er gemt i filen `paydata2017.txt`. Du gør datasættet tilgængeligt i R på følgende måde:

- Download filen `paydata2017.txt` fra Absalon og gem den et fornuftigt sted på din computer.
- Start RStudio og brug en af følgende kommandoer:

```
paydata2017 <- read.table("paydata2017.txt", header=TRUE)
paydata2017 <- read.csv("paydata2017.txt", sep="")
```

Bemærk: Hvis filen ikke ligger i den aktuelle “arbejdsmappe” (*working directory*), så skal du enten angive hele stien til filen eller skifte *working directory* til den relevante mappe, f.eks. via *Session* menuen.

- Nu skulle datasættet `paydata2017` gerne optræde i dit *Environment* vindue i RStudio og dermed være klar til brug.

Datasættet indeholder en linje for hver af de 934 personer; overraskende nok er personerne identificeret med navn. Du skal kun bruge variabelen `Pay` i denne opgave. Den indeholder den samlede løn, angivet i USD, i kalenderåret 2017 for de 934 personer.

Opgave

1. Indlæs datasættet som beskrevet ovenfor. Lav en ny variabel, `LogPay`, i datasættet. Den nye variabel skal indeholde den naturlige logaritme til værdierne i `Pay`.

Bestem derefter median, gennemsnit, stikprøvevarians og stikprøvespredning for variablene `Pay` og `LogPay`, dvs. udfyld følgende skema:

	Median	Gennemsnit	Stikprøvevarians	Stikprøvespredning
<code>Pay</code>	**	**	**	**
<code>LogPay</code>	**	**	**	**

2. Tegn et histogram for `Pay` på “sandsynlighedsskala”, dvs. således at det samlede areal under histogrammet er 1. Tegn tætheden for normalfordelingen med middelværdi og varians lig gennemsnit og stikprøvevarians for `Pay` i samme figur.

Lav den tilsvarende figur for `LogPay`.

Diskutér om det er mest fornuftigt at antage at lønnen normalfordelt eller at logaritmen til lønnen er normalfordelt. Argumentér ud fra figurerne og (nogle af) tallene fra tabellen ovenfor.

3. Brug en normalfordeling til at bestemme et fornuftigt estimat for sandsynligheden for at en tilfældig statsansat i Connecticut tjente mere end 100000 USD i 2017.

Beregn et andet fornuftigt estimat for den samme sandsynlighed, men hvor du ikke laver nogle normalfordelingsantagelser. Ligger de to estimater tæt på eller langt fra hinanden?

Lad i det følgende X være en stokastisk variabel med $X \sim \mathcal{N}(\mu, \sigma^2)$, og definer $Y = e^X$.

4. Vis at tætheden for Y er givet ved

$$f(y) = \frac{1}{y\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(\log y - \mu)^2}{2\sigma^2}\right), \quad y > 0.$$

Du kan enten bruge transformationssætningen (BH, Sætning 8.1) eller først bestemme fordelingsfunktionen (cdf'en) for Y og dernæst tætheden. Bemærk at transformations-sætningen gennemgås ved forelæsningerne fredag i kursusuge 4, hvorimod de nødvendige redskaber til rådighed til at løse opgaven via cdf'en allerede er gennemgået i kursusuge 3.

Fordelingen med tæthed f kaldes den *logaritmiske normalfordeling*, eller bare *log-normalfordelingen* — fordi logaritmen til en stokastisk variabel med denne tæthed er normalfordelt.

5. Forklar hvorfor det er fornuftigt at bruge log-normalfordelingen til at beskrive fordelingen af **Pay**. Gør herunder rede for hvilke af de værdier μ og σ^2 i definitionen af tætheden f .

Tegn histogrammet over **Pay** igen. Indtegn derefter grafen for tætheden f med de relevante værdier af μ og σ i samme graf, og kommentér grafen.

Medianen for en kontinuert stokastisk variabel Z med fordelingsfunktion F er den værdi c hvor $F(c) = 0.5$, altså $P(Z \leq c) = 0.5$.

Antag som i spørgsmål 4 at $X \sim \mathcal{N}(\mu, \sigma^2)$ og at $Y = e^X$.

6. Gør rede for at X har median μ , og vis derefter at Y har median e^μ .
7. Et af følgende udtryk for $E(Y)$ er korrekt:

$$E(Y) = e^\mu, \quad E(Y) = e^{\mu - \sigma^2}, \quad E(Y) = e^{\mu + \sigma^2}, \quad E(Y) = e^{\mu + \sigma^2/2}, \quad E(Y) = e^{\mu + \sigma}$$

Undersøg ved hjælp af simulation med $\mu = 0$ og $\sigma = 1.5$ hvilket af udtrykkene der er det korrekte. Brug mindst 10000 simulerede værdier. (Man kan ikke vise ved simulation at et sådant udtryk gælder generelt, men fire af udtrykkene kan udelukkes, og et af dem er faktisk korrekt!)

8. Brug det relevante udtryk og de relevante værdier for μ og σ^2 til at bestemme et fornuftigt estimat for den gennemsnitlige løn for statsansatte i Connecticut i 2017. Sammenlign med det relevante tal fra tabellen fra Spørgsmål 1 (hvilket?).

Man bruger normalt såkaldte *QQ-plots* til at vurdere om data kan antages at være normalfordelte. Dette er beskrevet i SM afsnit 2.6 på side 12.

9. Læs teksten om QQ-plots i SM, og lav QQ-plots for **Pay** og **LogPay**. Kommentér figurerne. Er konklusionen fra figurerne i overensstemmelse med jeres undersøgelser tidligere i opgaven?

Bonusinfo

Information om løn for samtlige statsansatte i Connecticut fra 2015 og frem kan downloades fra følgende site:

<https://data.ct.gov/Government/State-Employee-Payroll-Data-Calendar-Year-2015-thr/9m78-yc88/>

Datasættet til denne opgave er lavet ved at udvælge 934 tilfældige personer (dog valgt så de opfylder visse kriterier) blandet de mere en 100000 ansatte i 2017. Egentlig ville vi gerne have brugt nyere data, men det viste sig at løndata fra de seneste år *ikke* er log-normalfordelte. De har for tunge haler både nedadtil og opadtil og er derfor ikke velegnede til at illustrere den logaritmiske normalfordeling. Så selvom man ofte siger at løndata kan beskrives fornuftigt med log-normalfordelingen, så er det bestemt ikke altid tilfældet.

R-hjælp og andre vink

1. Se side 10 i RR for et eksempel hvor `transform` er brugt (eller brug `$`-syntaksen til at lave den nye variabel). Husk at den naturlige logaritme hedder `log` i R.

Se side 10–11 i RR for beregning af medianen, $\bar{x}$, s^2 og s . Husk at du kan bruge `$`-syntaksen når du skal bruge en variabel fra et datasæt, fx `paydata2017$Pay`.

2. Kommandoen `hist(x, prob=TRUE)` laver et histogram på sandsynlighedsskala for vektoren `x`, se også side 12–13 i RR. Tætheden for normalfordelingen kan udregnes og indtegnes i et allerede eksisterende plot på følgende måde, hvor `**` skal erstattes af de relevante tal:

```
f1 <- function(x) dnorm(x, mean=**, sd=**)
curve(f1, add=TRUE, col="red")
```

Se evt. også side 254 i BH.

3. Første del: Hvilken variabel bør I bruge når I skal bruge normalfordelingen? Brug funktionen `pnorm()` med passende argumenter, se evt. side 16–17 i RR eller side 253 i BH.

Anden del: Se side 6 i RR for hvordan man laver binære variable med værdierne `TRUE` og `FALSE` (logiske variable). Kombinér f.eks. dette med funktionen `sum()` eller `mean()`.

4. Hvis du går via cdf'en: Omskriv $P(Y \leq y)$ til en sandsynlighed der vedrører X og derefter til en sandsynlighed der vedrører en $\mathcal{N}(0, 1)$ -fordelt variabel. Husk at fordelingsfunktion for $\mathcal{N}(0, 1)$ betegnes Φ , og at $\Phi' = \phi$ (BH side 232).

5. Hvilken variabel skal I tænke på som X , hvilken variabel skal I tænke på som Y ?

Til tegningen får du brug for at definere en funktion `f2`:

```
f2 <- function(y) ** # Det relevante udtryk
```

Brug desuden `curve()` som i Spørgsmål 2.

6. Anden del: Hvad er det I skal vise? Husk at man kan regne under almindeligt inde i sandsynlighedsparenteser.

7. Simuler først værdier af X vha. `rnorm()`, se side 17 i RR eller side 253 i BH. Hvordan kan disse værdier bruges til at lave simulationer af Y ?
9. Brug funktionen `qqnorm()`. Hvad skal I kigge efter i figurerne?

Slut på opgaven.